

财务风险预警 · 数据用对没有值多少分

一个端到端可复跑的 LightGBM 落地：公开定期报告 → 风险名单，并把「谁在什么时刻能看见什么」变成可量化的分数差 · 2026-09 · 本地仓库 C:\dev\finlab-ml (6 笔提交 · 8 条命令复跑 · 公开仓待定)

问题

- 风控模型「离线好看、上线不行」，多数不是模型问题，是**数据用错**：拿还没披露的报表当输入、用未来的样本训练、把「最近一次披露日」当成首次披露日。
- 这类错**不报警**：跑得通、分数更高、看着更漂亮 → 每格都要有一条**不用人当裁判**的判据。



做了什么

- 面板**：A 股 2016Q1–2026Q2 · **42 期** · **195,707 行** · **5,252 只股票**（东财四张批量表 + **巨潮披露时间表**当 PIT 锚点）。**任务**：样本 = (代码, 年份) 取**一季报**，标签 = **当年年报亏损**，决策时刻 = **一季报实际披露日**（中位 4/23）⇒ 真实前瞻 8–12 个月。
- 四格对照**（同一份数据 / 同一个模型 / 同一个测试集，只改「数据用对没有」）：A 诚实 (PIT + 逐年游走) · B 偷看未来一期（多接一张半年报）· C 随机切分（训练集含未来年份）· D 负对照（训练标签打乱）；基线 = 会计持续性。
- 披露链五格**：一季报 → 半年报 → 三季报 → **业绩预告** → 年报，每格只用那一刻真的能看见的东西；另做**信号时间线**（同一批公司「有没有进前 10%」的轨迹）。

最硬的读数

臂	改了什么	AUC	top-10% 里真亏的比例
A 诚实	——	0.9103	84.95% （基准 23.9% ⇒ lift 3.55）
B 偷看未来一期	特征 + 半年报（ 121 天后才披露 ）	0.9442	92.40%
C 随机切分	训练集含未来年份	0.9246	87.63%
D 负对照	训练标签打乱（5 个种子）	0.4993 ± 0.0637	25.2%
基线：上年是否亏损	不训练	0.7512	70.4%

- 「偷看一期」的那 **3.4 分** ≈ **老老实实等到 8 月的合法分** (0.9442 vs **0.9427**) ⇒ **偷的不是更强的模型，是提前量**：该问的是「为提前多久，愿意放弃多少分」。A 臂逐年 0.891 / 0.896 / 0.922 / 0.928，三种子极差 0.001 ⇒ 这个差远在噪声外。
- 信号什么时候亮**：会亏的公司进前 10% 的比例 **4 月 35.6% → 8 月 38.5% → 10 月 40.1%**（误报 2.0% → 0.6%）；**43.8% 的亏损公司从未亮灯** ⇒ **预警的天花板不是模型，是基本面在哪一天开始变难看**。
- 数据源本身的坑**：东财批量表的「公告日期」**不是首次披露日**，而是「最近一次披露该期数字的公告日」——带「上年同期」栏的报表**全期次晚 365 天**；证据：茅台 2016Q1 实际 2016-04-21、东财利润表写 2017-04-25。



信号什么时候亮：红线 = 真会亏的公司，蓝线 = 误报。

提前量 → 判别力：红线是「偷看一期」那 3.4 分，正好切在半年报那个点上。

一条最值钱的方法论

- 任何「差多少分」先确认两次读数在**同一批样本上**：C 臂 0.9246 对比 A 的 0.9103 看着是 +1.4 分，但两批测试样本不同；把 A 限制到同一批重算是 **0.9122** ⇒ 真差 **+1.24 分**。
- 负对照要给分布、不给点**：单种子 0.5488 看着「偏高」，5 个种子给出 **0.4993 ± 0.0637** (0.403–0.583) 才落回 0.5。跨阶段只比阶段内分位、分母要一致、并列会把「前 10%」判没（三条都写进了 docs/口径.md）。

诚实边界

- 标签是「**年报亏损**」不是「**被 ST**」（可靠 ST 名单拿不到）；**退市样本缺失** ⇒ 正例率偏低；**只有日期做了双源对账**，面板数值没有。预告那格是子集（正例率 43.8%），不与 4/8/10 月三格直接比；业绩快报那格**做不了**（PIT 锚点被污染）——「**做不了**」和「**没做**」分开写。
- 不许把 **96.2% 的精确率**读成召回：前 10% 名单里 96.2% 真会亏，但它只覆盖 **40%** 的亏损公司。