

财务风险预警 · 数据用对没有值多少分

一个端到端可复跑的 LightGBM 落地：公开定期报告 → 风险名单，并把「谁在什么时刻能看见什么」变成可量化的分数差 · 2026-09 · 本地仓库 C:\dev\finlab-ml (33 笔提交 · 10 条命令复跑 · 公开仓待定)

问题

- 风控模型「离线好看、上线不行」，多数不是模型问题，是**数据用错**：拿还没披露的报表当输入、用未来的样本训练、把「最近一次披露日」当成首次披露日。
- 这类错**不报警**：跑得通、分数更高、看着更漂亮 → 每格都要有一条**不用人当裁判**的判据。



做了什么

- 面板**：A 股 2016Q1–2026Q2 · **42 期** · **195,707 行** · **5,252 只股票**（东财四张批量表 + **巨潮披露时间表**当 PIT 锚点）。**任务**：样本 = （代码，年份）取**一季报**，标签 = **当年年报亏损**，决策时刻 = 一季报**实际披露日**（中位 4/23）⇒ 真实前瞻 8–12 个月。
- 四格对照**（同一份数据 / 同一个模型 / 同一个测试集，只改「数据用对没有」）：A 诚实（PIT + 逐年游走）· B 偷看未来一期（多接一张半年报）· C 随机切分（训练集含未来年份）· D 负对照（训练标签打乱）；基线 = 会计持续性。
- 披露链五格**：一季报 → 半年报 → 三季报 → **业绩预告** → 年报，每格只用那一刻真的能看见的东西；另做**信号时间线**与**监管口径的第二组标签**（见下）。

最硬的读数

臂	改了什么	AUC	top-10% 里真亏的比例
A 诚实	——	0.9103	84.95% （基准 23.9% ⇒ lift 3.55）
B 偷看未来一期	特征 + 半年报（ 121 天后才披露 ）	0.9442	92.40%
C 随机切分	训练集含未来年份	0.9246	87.63%
D 负对照	训练标签打乱（5 个种子）	0.4993 ± 0.0637	25.2%
基线：上年是否亏损	不训练	0.7512	70.4%

- 「偷看一期」的那 **3.4 分** ≈ **老老实实等到 8 月的合法分**（0.9442 vs **0.9427**）⇒ **偷的不是更强的模型，是提前量**：该问的是「为提前多久，愿意放弃多少分」。A 臂逐年 0.891 / 0.896 / 0.922 / 0.928，三种子极差 0.001 ⇒ 这个差远在噪声外。
- 信号什么时候亮**：会亏的公司进前 10% 的比例 **4 月 35.6% → 8 月 38.5% → 10 月 40.1%**（误报 2.0% → 0.6%）；**43.8% 的亏损公司从未亮灯** ⇒ **预警的天花板不是模型，是基本面**在哪一天开始变难看。
- 数据源本身的坑**：东财批量表的「公告日期」**不是首次披露日**，而是「最近一次披露该期数字的公告日」——带「上年同期」栏的报表**全期次晚 365 天**；证据：茅台 2016Q1 实际 2016-04-21、东财利润表写 2017-04-25。
- 换成监管口径的标签**（自建 as-of「被实施风险警示」：**952 次戴帽 / 606 家**）：AUC **0.910 → 0.813**，但前 10% 名单**抓住 49% 的戴帽事件**（亏损标签只有 36%）、**lift 4.89×** ⇒ **目标越稀有，AUC 越高，名单反而越值钱**。



信号什么时候亮：红线 = 真会亏的公司，蓝线 = 误报。

提前量 → 判别力：红线是「偷看一期」那 3.4 分，正好切在半年报那个点上。

一条最值钱的方法论

- 任何「差多少分」先确认两次读数在同一批样本上**：C 臂 0.9246 对比 A 的 0.9103 看着是 +1.4 分，但两批测试样本不同；把 A 限制到同一批重算是 **0.9122** ⇒ 真差 **+1.24 分**。
- 「分得开」≠「加得进」：诉讼/担保信号单独看差 **17.6 个点**，加进模型只值 **+0.0014**；当第二条通道扩名单，又被**同等规模的模型名单**支配——这条曾让我**撤回**一个结论。
- 负对照要分布、且必须用 macro 读**：无信号模型 pooled 下能读到 **0.555 / 0.407**，macro 才回到 **0.5**；跨阶段只比分位、分母要一致（见 docs/口径.md）。

诚实边界

- 主表用「**年报亏损**」；ST 标签已做成 as-of（第二组读数，但每年只有 **20–74 个正例** ⇒ 只能四年合并报）。**退市样本缺失**（最该抓的一批被剔除）；日期与面板数值都做了**双源全量对账**（净利润同名只 23%、对齐概念后 99.6%）。
- 别把 **96.2% 的精确率**读成召回（前 10% 名单只覆盖 **40%** 的亏损公司）；预告那格是**子集**（43.8% 正例率），**业绩快报**那格**做不了**（PIT 锚点被污染）。
- 「为什么戴帽」已归类（211 份公告正文）：「没亏但戴帽」那批 **约 64% 是治理/合规类**（内控被否 · 行政处罚 · 账户冻结 · 资金占用），纯财务类只约 20% ⇒ **触发规则不在报表里**，这才是天花板；边界：① 组仅 45 条、关键词规则。